

从 RNN 到 Mamba: 状态建模视角下的序列模型演化

陈奕韬

2026 年 4 月 16 日

目录

RNN：状态压缩的起点

Transformer：显式检索历史

SSM：重新回到状态建模

Mamba：Selective SSM

RNN：用隐藏状态压缩整个历史

- ▶ 给定输入序列 $x_{1:T}$ ，RNN 通过递推状态建模历史：


$$h_t = \phi(W_x x_t + W_h h_{t-1} + b), \quad y_t = W_o h_t.$$

- ▶ 核心假设：固定维度隐藏状态 h_t 足以概括过去全部信息。
- ▶ 优势：在线推理自然、单步更新代价低、适合流式建模。
- ▶ 局限：
 - ▶ 梯度沿时间链传播，易出现 vanishing/exploding gradient；
 - ▶ 训练沿时间维串行，硬件并行效率受限；
 - ▶ 长历史被压入固定状态，形成 state bottleneck。

LSTM/GRU 通过门控改善长期依赖，但没有改变“串行 + 固定状态压缩”的基本范式。

为什么 RNN 让位于 Transformer ?

- ▶ 对位置 i 依赖位置 j 的信息，RNN 的传播路径长度约为 $|i - j|$ 。
- ▶ 大量历史被压缩到有限维状态，因而精确回看远处 token 较困难。
- ▶ 训练依赖 BPTT，序列越长越难稳定，且硬件并行效率受限。
- ▶ 研究重心因此转向：**直接建立跨位置交互，而非只依赖链式状态传递。**



Transformer: 用自注意力显式访问全部上下文

- ▶ 自注意力直接建模 token-token 交互:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V.$$

- ▶ 关键收益:
 - ▶ 任意两位置间路径长度为 1, 长程依赖更易学习;
 - ▶ 整个序列可并行训练, 适合 GPU/TPU;
 - ▶ 在 NLP 中成为主流大模型主干。
- ▶ 代价: 对长度为 N 的序列, 标准 self-attention 的时间与显存通常为

$$O(N^2).$$

从 RNN 到 Transformer: 本质是记忆机制的变化

模型	历史如何存储	训练方式	主要瓶颈
RNN/LSTM Transformer	压缩进隐藏状态 h_t 显式保留全部 token 表示	时间维串行 高并行	长依赖与状态瓶颈 $O(N^2)$ 注意力

- ▶ RNN 重在“状态递推”；Transformer 重在“显式检索历史”。
- ▶ 后续高效模型试图统一两者：训练时并行，推理时递推。

什么是状态空间模型 (State Space Model, SSM) ?

- ▶ 状态空间模型源自控制理论，用一个隐状态 h_t 描述系统的内部动态。
- ▶ 其离散形式通常可写为：

$$h_t = \bar{A}h_{t-1} + \bar{B}x_t, \quad y_t = Ch_t.$$

- ▶ 其中：
 - ▶ x_t ：当前输入；
 - ▶ h_t ：当前状态，用于压缩历史；
 - ▶ $\bar{A}$ ：控制过去状态如何传播；
 - ▶ $\bar{B}$ ：控制当前输入如何写入状态；
 - ▶ C ：控制如何从状态中读出输出。
- ▶ 从形式上看，SSM 与 RNN 很接近：都是“输入 + 上一状态 $\rightarrow$ 新状态”的递推过程。
- ▶ 不同之处在于，SSM 更强调**结构化的状态转移**，因此更容易分析长程动态性质。

为什么 SSM 会重新受到关注？

- ▶ RNN 的问题在于：虽然也是递推状态模型，但训练串行、长依赖困难，且状态更新缺乏足够结构。
- ▶ Transformer 则通过显式注意力解决了长依赖问题，但标准 attention 在长序列下通常具有 $O(N^2)$ 代价。
- ▶ SSM 因而提供了一条折中路线：
 - ▶ 仍然保留“状态递推”的线性扩展优势；
 - ▶ 但通过结构化动力系统增强长程建模能力；
 - ▶ 在某些形式下还可以转化为高效卷积计算。
- ▶ 以 S4 为代表的结构化状态空间模型说明：
 - ▶ 状态模型不一定只能像传统 RNN 那样训练困难；
 - ▶ 经过适当结构设计后，也可以兼顾长序列建模与计算效率。
- ▶ 不过，早期 SSM 仍有一个重要不足：参数通常固定，缺乏对输入内容的选择性响应。
- ▶ 这正是 Mamba 进一步改进的出发点。

Mamba: 选择性状态空间模型 (Selective SSM)


- ▶ Mamba 的核心不是简单地继续使用固定参数的 SSM，而是让部分状态空间参数随当前输入变化，从而实现 **content-based reasoning**。
- ▶ 一个简化表达为：

$$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t, \quad y_t = C_t h_t.$$

- ▶ 与经典 LTI-SSM 相比，关键区别在于：
 - ▶ 状态更新不再对所有 token 完全相同；
 - ▶ 模型可以根据当前内容决定“写入多少、保留多久、输出什么”；
 - ▶ 因而更适合处理语言中常见的选择性记忆与上下文检索问题。
- ▶ 论文强调：早期 SSM 的主要短板并不是线性复杂度不足，而是缺乏这种输入相关的选择性机制。
- ▶ 因此，Mamba 可以看作是在 S4 基础上，引入选择性更新后的 SSM 骨干网络。

Mamba block: 结构与关键算子

- ▶ Mamba block 由三部分组成：
 - ▶ 线性投影与局部卷积：提取短程模式；
 - ▶ selective SSM：进行内容相关的状态更新；
 - ▶ 门控与残差：控制信息流并保持训练稳定。
- ▶ 难点在于：当参数依赖输入时，SSM 不再对应固定卷积核，因而不能直接沿用 S4 的卷积式实现。
- ▶ 论文的关键工程贡献是 **hardware-aware parallel scan**：在保留输入相关递推的同时，尽量维持高效并行训练。



Mamba 的关键在于：将选择性参数生成、状态更新与高效 scan 整合进统一 block。

为什么 Mamba 在长序列上有吸引力？

- ▶ Transformer 自回归推理通常需要维护随上下文增长的 KV cache。
- ▶ Mamba 推理时每层仅维护固定大小状态；新 token 到来时只做一次状态递推更新。
- ▶ 因而它同时具有两方面优势：
 - ▶ **系统上**：推理内存不随上下文持续膨胀；
 - ▶ **建模上**：Selective SSM 可有选择地保留重要信息。
- ▶ 因此，Mamba 兼具较好的长序列扩展性、状态化推理能力，以及相对较强的训练并行性。

模型	训练并行性	推理缓存	长序列扩展性
RNN/LSTM Transformer	弱 强	固定状态 KV cache 随长度增长	线性，但选择性有限 通常 $O(N^2)$
S4 类 SSM	中-强	固定状态	线性，但内容选择性弱
Mamba	中-强	固定状态	线性，且具输入相关性

从 RNN 到 Mamba: 统一视角总结

- ▶ **RNN/LSTM**: 历史压缩进隐藏状态, 推理高效, 但训练串行且长依赖困难。
- ▶ **Transformer**: 通过 self-attention 显式访问历史, 训练强并行, 但长序列成本高。
- ▶ **SSM/S4**: 回归状态建模, 用结构化动力系统兼顾长程建模与线性扩展。
- ▶ **Mamba**: 在 SSM 中引入内容选择性, 使状态更新能够随输入内容自适应变化。